

¿ESTÁN BIEN CALIBRADAS LAS CASAS DE APUESTAS?

Evaluación de pronósticos probabilísticos con datos históricos de cuotas

Valentina Cabarcas de la Hoz, Mariana Carrillo Candanoza y Albert Devanis Gastelbondo Suárez

Proyecto 2: Estadística Industrial

Ingeniería Industrial · Universidad del Magdalena

Docente: Enrique J. De La Hoz Domínguez

Semestre 2026-II

Santa Marta, Colombia, octubre de 2026

1. Resumen

Este trabajo evalúa la calibración de las probabilidades implícitas en las cuotas de cierre (último precio ofrecido por el operador antes del inicio del partido) de Bet365 (B365), Betway/BetAndWin (BW) e Interwetten (IW) para 377 partidos válidos de la Premier League 2021/22. La pregunta central es si las probabilidades de cierre están bien calibradas y si la calidad de calibración cambia según el nivel de probabilidad implícita. Como análisis complementarios se estima la probabilidad de que el equipo visitante anote al menos un gol y se cuantifica el margen comercial del mercado.

Las métricas muestran que las cuotas contienen información predictiva: los Brier Scores (BS, error cuadrático medio entre la probabilidad predicha y el resultado observado; un valor menor indica mejor desempeño) se sitúan entre 0,178 y 0,200, por debajo de la línea de referencia de 0,2222 utilizada en el proyecto, mientras los ECE (Expected Calibration Error, desajuste absoluto ponderado entre la probabilidad predicha y la frecuencia real observada por intervalo) oscilan entre 0,023 y 0,087. La calibración no es uniforme por nivel: el grupo de probabilidad media presenta el ECE más alto, 0,1001, frente a 0,0584 en el nivel bajo y 0,0549 en el alto. El margen medio agregado es 5,393 %, con medias de 5,533 % para B365, 5,616 % para BW y 5,029 % para IW. El visitante anotó al menos un gol en 68,70 % de los partidos. Finalmente, la mayor diferencia promedio entre métodos de remoción del margen fue 0,0080, por lo que la lectura general es estable frente al método de normalización.

En conjunto, los resultados son compatibles con un mercado de cierre razonablemente bien calibrado, aunque con desajustes locales que deben interpretarse junto con el margen, la dependencia entre partidos y la incertidumbre de los intervalos. El estudio es retrospectivo y no constituye una estrategia ni una recomendación de apuesta.

Palabras clave: calibración, probabilidades implícitas, overround, Brier Score, ECE, cuotas de cierre, fútbol.

2. Marco conceptual

2.1 Calibración de pronósticos probabilísticos

Un pronóstico probabilístico está bien calibrado cuando la frecuencia observada de un evento coincide, en promedio, con la probabilidad asignada. Si un sistema atribuye una probabilidad cercana a 0,70 a un conjunto amplio de eventos comparables, se espera que alrededor del 70 % ocurra. Esta propiedad se diferencia de la simple exactitud: un sistema puede acertar con frecuencia la categoría más probable y, al mismo tiempo, asignar probabilidades excesivas o insuficientes.

$$P(y = 1 \mid \hat{p} = p) = p, \quad p \in [0, 1]$$

La herramienta gráfica más directa es el diagrama de fiabilidad. Las predicciones se agrupan en intervalos y se compara la probabilidad media con la frecuencia observada en cada grupo. Una curva próxima a la diagonal representa buena calibración; una curva por debajo indica sobrestimación y una curva por encima indica subestimación. Debido a que el resultado depende de cuántas observaciones contiene cada intervalo, la lectura debe acompañarse del tamaño muestral y de un análisis de sensibilidad al número de grupos (DeGroot & Fienberg, 1983).

La calibración y la discriminación responden preguntas distintas. La primera evalúa si los porcentajes declarados son coherentes con las frecuencias reales; la segunda, si el pronóstico separa adecuadamente escenarios con distinto riesgo. Por eso las curvas se complementan con reglas de

puntuación como el Brier Score, que resume el error de las probabilidades sin reducir el análisis a una tasa de acierto.

2.2 Cuotas, probabilidades implícitas y margen

Para una cuota decimal o , la probabilidad implícita bruta se obtiene mediante:

$$p_{bruta} = \frac{1}{o}$$

En un mercado 1X2 existen tres resultados posibles: victoria local, empate y victoria visitante. Si las cuotas fueran precios justos, las tres probabilidades sumarían exactamente 1. En la práctica, la suma supera la unidad porque el operador incorpora un margen comercial u overround.

$$M = \frac{1}{C_H} + \frac{1}{C_D} + \frac{1}{C_A} - 1$$

El margen es central para interpretar las cuotas. Una probabilidad bruta incluye simultáneamente la información del mercado y la comisión implícita del operador. Por esta razón, comparar directamente probabilidades brutas con frecuencias observadas produce una evaluación sesgada. El análisis de calibración debe realizarse con probabilidades ajustadas cuya suma sea 1 (Constantinou & Fenton, 2013; Shin, 1993).

2.3 Remoción del margen y reglas de evaluación

Existen varias formas de retirar el overround y cada una supone una distribución diferente del margen entre los resultados. El método multiplicativo conserva las proporciones relativas; el aditivo resta una fracción común a cada resultado; y el método logarítmico o de potencia aplica una corrección no lineal. Comparar métodos permite verificar si una conclusión se debe al fenómeno observado o a una decisión técnica de normalización (Štrumbelj, 2014).

El Brier Score cuantifica el error cuadrático de las probabilidades. Un valor menor representa mejor desempeño bajo la convención empleada en este proyecto. El Expected Calibration Error, ECE, resume el desajuste absoluto entre la probabilidad media y la frecuencia observada, ponderando cada intervalo por su número de observaciones. Ambas métricas se interpretan en conjunto: el Brier Score resume el desempeño global, mientras el ECE ayuda a localizar errores sistemáticos de calibración.

2.4 Nivel de probabilidad y patrón favorito-longshot

La literatura de mercados de apuestas ha documentado que la calidad de las probabilidades puede cambiar a lo largo del rango, especialmente entre eventos muy poco probables y favoritos. En este informe no se asume de antemano que exista ese sesgo. Se examina si los errores son distintos en niveles de probabilidad baja, media y alta, y se describe si el patrón observado es compatible con lo reportado en estudios previos (Cain et al., 2000; Woodland & Woodland, 1994).

2.5 Encuadre del proyecto

El mercado de apuestas se utiliza aquí como un caso de estudio de pronósticos probabilísticos. El análisis es retrospectivo, se basa en datos históricos cerrados y tiene fines académicos. Una desviación de calibración no equivale a una oportunidad de ganancia, porque cualquier interpretación económica debe considerar el margen, la estabilidad temporal y la incertidumbre del resultado. Ninguna sección del informe propone estrategias de apuesta.

3. Datos

3.1 Fuente y alcance

Los datos provienen de football-data.co.uk, repositorio público que distribuye archivos CSV con resultados de partidos y cuotas históricas. Se utilizó el archivo E0.csv correspondiente a la Premier League inglesa 2021/22, con 380 partidos y cuotas de cierre. La documentación de variables disponible en football-data.co.uk/notes.txt fue utilizada para identificar las columnas de equipos, marcador, resultado final y precios 1X2. Fecha de descarga: 24/09/2026.

El alcance se restringió a una liga y una temporada para evitar mezclar tasas base de contextos competitivos diferentes y facilitar la trazabilidad del flujo. Se trabajó con cuotas de cierre porque representan la última cotización disponible antes del partido y concentran la información incorporada por el mercado hasta ese momento.

3.2 Operadores incluidos y excluidos

Se incluyeron Bet365, Betway/BetAndWin e Interwetten. Las columnas de cierre utilizadas fueron CH, CD y CA para local, empate y visitante en cada operador. Estos tres conjuntos permitieron construir una base común después de la limpieza. Pinnacle no formó parte del archivo utilizado para el análisis. Además, la fuente advierte que desde el 23 de julio de 2025 sus cuotas presentan problemas de actualización; esa advertencia se documenta para impedir que una futura ampliación confunda un artefacto de recolección con una diferencia de calibración.

Otros operadores no se incorporaron porque el objetivo fue mantener una comparación consistente entre las casas con las variables de cierre disponibles en el flujo desarrollado. La cobertura debe reconstruirse en cada temporada, ya que la presencia de operadores y columnas cambia a lo largo del tiempo.

3.3 Limpieza, validación e inventario de cobertura

El proceso de limpieza siguió cuatro controles. Primero se revisaron duplicados exactos y combinaciones repetidas de fecha, equipo local y visitante. Segundo, se verificó que las cuotas fueran numéricas y mayores que 1. Tercero, se comprobó que los goles al descanso no superaran los goles finales. Cuarto, se verificó que la variable de resultado fuera coherente con el marcador. Solo el control de cuotas eliminó registros: tres partidos tenían al menos un valor no válido, asociado a IW. Al aplicar el filtro de forma común, la base final quedó en 377 partidos para los tres operadores.

Regla	Descripción	Excluidos	Quedan
R1	Duplicados por fecha y equipos	0	380
R2	Cuotas numéricas y mayores que 1	3	377
R3	Consistencia de goles HT y FT	0	377
R4	Coherencia entre FTR y marcador	0	377

Tabla 1. Reglas de limpieza aplicadas en secuencia.

Operador	Partidos originales	Registros excluidos globalmente	Disponibles finales	Cobertura
B365	380	3	377	99,21 %
BW	380	3	377	99,21 %
IW	380	3	377	99,21 %

Tabla 2. Inventario de cobertura después de aplicar una base común de 377 partidos.

En la muestra final se registraron 161 victorias locales (42,7 %), 88 empates (23,3 %) y 128 victorias visitantes (34,0 %). Las fechas deben interpretarse en formato día/mes/año. La base analítica conserva para cada partido el resultado observado, las cuotas originales, las probabilidades implícitas, el margen y las probabilidades normalizadas, lo que permite rastrear cada cifra del informe hasta su registro de origen.

4. Metodología

4.1 Conversión de cuotas y remoción del margen

Cada cuota de cierre se transformó primero en probabilidad implícita bruta mediante su inverso. Después se calculó el margen como el exceso sobre 1 de la suma de las tres probabilidades. Dado que la calibración debe evaluarse sobre probabilidades libres de margen, se aplicaron tres métodos de normalización con supuestos distintos sobre la distribución de ese exceso.

Método multiplicativo. Distribuye el margen de manera proporcional a la probabilidad bruta de cada resultado. La probabilidad ajustada se obtiene dividiendo cada probabilidad implícita entre la suma de las probabilidades de local, empate y visitante:

$$\hat{p}_{mult,i} = \frac{p_{bruta,i}}{\sum_j p_{bruta,j}}$$

Es el procedimiento más simple y conserva la proporción relativa entre los tres resultados. Su supuesto principal es que el margen se distribuye proporcionalmente entre ellos.

Método aditivo. Distribuye el margen total (M) en partes iguales entre los tres posibles resultados. Para cada probabilidad se resta una tercera parte del margen:

$$\hat{p}_{adit,i} = p_{bruta,i} - \frac{M}{k}$$

Este método supone que el margen afecta por igual a local, empate y visitante. Sin embargo, puede producir probabilidades negativas cuando alguna probabilidad bruta (p_i) es menor que ($M/3$). Esta

posibilidad fue contemplada explícitamente en el procedimiento, aunque en la base analizada no se presentaron valores negativos.

Método logarítmico o de potencia. Aplica una transformación no lineal mediante un exponente (n).

Este exponente se determina de forma que las probabilidades ajustadas sumen exactamente 1:

$$\sum_i p_{bruta,i}^n = 1$$

$$\hat{p}_{log,i} = p_{bruta,i}^n$$

Para encontrar el exponente se utilizó el método numérico de Newton-Raphson, que lo ajusta de forma iterativa hasta lograr que las probabilidades normalizadas sumen exactamente 1. Este procedimiento mantiene siempre probabilidades positivas, por lo que es una alternativa útil cuando el método aditivo podría generar valores negativos. En el análisis, el exponente promedio fue 1,060, con valores entre 1,034 y 1,194, y se utilizó junto con los otros métodos para comprobar la sensibilidad de los resultados.

4.2 Agrupamiento de la curva de calibración

Las probabilidades normalizadas se agruparon inicialmente en 10 intervalos de igual ancho: [0; 0,1], (0,1; 0,2], hasta (0,9; 1,0]. En cada intervalo se calculó la probabilidad media pronosticada y la frecuencia observada. El esquema de igual ancho facilita la lectura directa de desviaciones en distintas zonas del rango y permite identificar si los errores aparecen en probabilidades bajas, medias o altas.

Para comprobar que las conclusiones no fueran un artefacto del número de intervalos, se repitió el análisis con 5 y 20 grupos. También se analizaron por separado victoria local, empate y victoria visitante, ya que cada resultado posee una tasa base y una distribución de probabilidades diferente.

4.3 Desviaciones sistemáticas por nivel de probabilidad

Se definieron tres niveles: baja ($p < 0,40$), media ($0,40 \leq p \leq 0,60$) y alta ($p > 0,60$). Para cada nivel se calcularon el Brier Score y el ECE. Esta clasificación permite evaluar si la calibración cambia con la magnitud de la probabilidad y sirve como aproximación al análisis del patrón favorito-longshot sin convertirlo en una afirmación causal.

4.4 Reglas de puntuación

Brier Score (BS). Mide el error cuadrático medio entre la probabilidad predicha y el resultado binario:

$$BS = \frac{1}{N} \sum_i (\hat{p}_i - y_i)^2$$

Un valor menor representa mejor desempeño. Se utiliza 0,2222 como línea base de comparación del proyecto, de modo que una puntuación inferior indica que las probabilidades contienen información útil respecto de esa referencia.

Expected Calibration Error (ECE). Resume las diferencias absolutas entre probabilidad media y frecuencia observada, ponderadas por el tamaño de cada intervalo:

$$ECE = \sum_b \frac{n_b}{N} \times |\bar{p}_b - f_b|$$

Un ECE igual a 0 representaría calibración perfecta. Como indicador complementario se reportó la proporción de partidos en los que el resultado con mayor probabilidad coincidió con el observado; esa tasa de acierto no sustituye a una métrica probabilística.

4.5 Dependencia, incertidumbre y pruebas

Los tres operadores fijan precios sobre los mismos 377 partidos, por lo que las comparaciones entre casas son apareadas. Además, los encuentros de una misma temporada comparten equipos, calendario y contexto, lo que introduce dependencia adicional. Por estas razones no se emplearon pruebas de muestras independientes ni se interpretaron p-valores asintóticos como evidencia concluyente. La incertidumbre de las curvas se valoró mediante el número de observaciones de cada intervalo y la estabilidad del patrón al cambiar de 5 a 10 y 20 intervalos. En los extremos, donde algunos grupos tienen pocos casos, las desviaciones se interpretan con mayor cautela. Un desarrollo posterior podría incorporar intervalos de Wilson o remuestreo por partido o equipo, preservando la estructura de dependencia.

5. Resultados

5.1 Distribución del margen del mercado

Todos los partidos presentaron margen positivo. El promedio agregado fue 5,393 %, con un rango entre 3,704 % y 7,937 %. B365 registró una media de 5,533 %, BW de 5,616 % e IW de 5,029 %. IW también presentó la menor dispersión en la tabla descriptiva. Estos valores confirman que el overround es suficientemente grande como para que la remoción del margen sea un paso obligatorio antes de evaluar calibración.

Operador	n	Media %	Mediana %	Mínimo %	Máximo %	DE %
B365	377	5,533	5,556	3,704	7,937	0,570
BW	377	5,616	5,602	3,846	7,190	0,601
IW	377	5,029	5,073	3,896	5,861	0,414
Total	1 131	5,393	5,376	3,704	7,937	0,594

Tabla 3. Estadísticos descriptivos del margen del mercado por operador.




Figura 1. Distribución del margen del mercado. Las líneas verticales representan promedio y mediana.

La forma de la distribución muestra concentración alrededor del 5 % al 6 %, pero el margen no es constante entre partidos. Por ello, aplicar un único descuento global sería menos apropiado que normalizar cada mercado de manera individual.

5.2 Calibración global y reglas de puntuación

Después de remover el margen, los tres operadores muestran un desempeño muy parecido. Los Brier Scores se encuentran entre 0,178 y 0,200, por debajo de la línea de referencia de 0,2222. El empate presenta BS cercano a 0,178 en las tres casas. El resultado local concentra los ECE más altos, entre 0,059 y 0,087, mientras empate y visitante presentan errores menores.

Operador	Resultado	Brier Score	ECE	Acierto
B365	Local	0,199	0,087	
B365	Empate	0,178	0,028	
B365	Visitante	0,179	0,041	58,89 %
BW	Local	0,200	0,078	
BW	Empate	0,178	0,023	
BW	Visitante	0,179	0,050	58,62 %
IW	Local	0,198	0,059	
IW	Empate	0,178	0,036	

Operador	Resultado	Brier Score	ECE	Acierto
IW	Visitante	0,179	0,037	58,89 %
Referencia	Cualquiera	0,2222	No aplica	

Tabla 4. Brier Score, ECE y porcentaje de acierto por operador y resultado.

Las diferencias entre operadores son pequeñas. Para un mismo tipo de resultado, la variación del Brier Score es inferior a 0,002. Esto sugiere que la información incorporada por las casas en el cierre es muy similar. Sin embargo, una buena métrica promedio puede ocultar errores locales, por lo que el análisis se complementa con la comparación por nivel de probabilidad.

Las desviaciones de una curva de calibración deben leerse junto con el número de observaciones de cada intervalo. Los grupos extremos contienen menos casos y, por tanto, mayor incertidumbre. La estabilidad al usar 5, 10 y 20 intervalos respalda la forma general del resultado, pero no reemplaza intervalos de confianza formales.

5.3 Calibración por nivel de probabilidad implícita

El comportamiento cambia a lo largo del rango de probabilidades. El nivel bajo presenta un Brier Score promedio de 0,2301 y ECE de 0,0584; el nivel medio, BS de 0,1882 y ECE de 0,1001; y el nivel alto, BS de 0,1279 y ECE de 0,0549. El nivel medio concentra el mayor error de calibración, mientras el nivel alto obtiene la mejor puntuación Brier.

Nivel	n aproximado	BS promedio	ECE promedio	Comparación con nivel medio
Baja, $p < 0,40$	710 a 730	0,2301	0,0584	+22,3 % en BS
Media, $0,40 \leq p \leq 0,60$	209 a 235	0,1882	0,1001	Referencia
Alta, $p > 0,60$	212 a 237	0,1279	0,0549	-32,0 % en BS

Tabla 5. Calibración promedio por nivel de probabilidad implícita.




Figura 2. Brier Score y ECE por nivel. El ECE es mayor en el grupo intermedio.

El patrón es compatible con diferencias de calibración según el nivel de probabilidad, pero no se interpreta como una prueba causal del sesgo favorito-longshot. Parte de la reducción del Brier Score en probabilidades altas puede estar asociada a la geometría del error cuadrático, por lo que el ECE y la sensibilidad metodológica son necesarios para completar la lectura.

5.4 Sensibilidad entre métodos de remoción del margen

Las diferencias entre métodos fueron pequeñas. El par aditivo y logarítmico fue el más cercano, con diferencia media 0,0010, mientras multiplicativo y logarítmico presentaron la mayor diferencia media, 0,0080.

5.5 Probabilidad de que el visitante anote al menos un gol

El visitante anotó al menos un gol en 259 de 377 partidos, equivalente a 68,70 %. La frecuencia varió ampliamente entre clubes: Liverpool anotó en 94,74 % de sus partidos como visitante, mientras Norwich City registró 36,84 %. La media de la liga describe la temporada completa, pero no sustituye un modelo condicionado por rival, localía, forma reciente u otras características.




Figura 3. Frecuencia de al menos un gol como visitante por equipo en la Premier League 2021/22.

Comparación	Diferencia media	Diferencia máxima
Multiplicativo vs. aditivo	0,0074	0,0349
Multiplicativo vs. logarítmico	0,0080	0,0440
Aditivo vs. logarítmico	0,0010	0,0125

Tabla 6. Sensibilidad de las probabilidades normalizadas según el método de remoción.

En 49,5 % de los partidos las diferencias entre los métodos fueron inferiores a 0,01 y el ajuste aditivo no produjo probabilidades negativas. En conjunto, margen, reglas de puntuación, análisis por nivel y sensibilidad apuntan a la misma conclusión: las cuotas de cierre contienen información predictiva, pero la calibración no es uniforme en todo el rango.

6. Discusión

6.1 Eficiencia del mercado y calidad de los pronósticos

Los resultados son compatibles con un mercado de cierre que incorpora información útil. Los Brier Scores se mantienen por debajo de la referencia del proyecto y las diferencias entre operadores son pequeñas, lo que coincide con la idea de que los precios tienden a converger cuando se aproxima el inicio del partido. Esta interpretación debe entenderse de manera limitada: eficiencia informativa no significa calibración perfecta ni ausencia de desajustes locales.

El análisis por nivel confirma esa cautela. Una métrica global aceptable puede coexistir con un ECE elevado en el rango medio. Además, el menor Brier Score del nivel alto no puede atribuirse exclusivamente a una mejor capacidad de pronóstico, porque el error cuadrático depende también de la posición de las probabilidades dentro del intervalo 0 a 1. El ECE y la estabilidad entre métodos ayudan a evitar una interpretación basada en una sola métrica.

6.2 Significancia estadística frente a relevancia práctica

El estudio distingue deliberadamente entre magnitud observada y significancia estadística. Los operadores valoran los mismos partidos y los partidos comparten equipos, por lo que las observaciones no forman grupos independientes. En consecuencia, el informe no presenta p-valores de pruebas independientes como evidencia concluyente. Las diferencias se describen mediante tamaños de error, consistencia entre casas y sensibilidad metodológica.

La relevancia práctica también requiere contexto. El margen medio agregado es 5,393 puntos porcentuales, magnitud mayor que muchas de las diferencias que aparecen entre métodos o entre operadores. Una desviación histórica de calibración, incluso si fuera estable en la muestra, no demuestra que pueda superar ese margen ni que continúe en temporadas futuras.

6.3 Comparación entre operadores y preguntas secundarias

B365, BW e IW presentan perfiles similares en Brier Score. IW obtiene el menor ECE local y el margen promedio más bajo, pero estas diferencias no permiten declarar que sea globalmente superior, porque no se aplicó un diseño inferencial que controle la dependencia y porque el análisis cubre una sola temporada.

La probabilidad de gol visitante, 68,70 %, responde una pregunta descriptiva distinta de la calibración. Su utilidad principal es mostrar la variabilidad entre equipos y la necesidad de condicionar cualquier modelo posterior. No debe interpretarse como una probabilidad universal aplicable a futuros partidos.

7. Limitaciones

7.1 Dependencia entre observaciones y comparaciones múltiples

La limitación principal es la dependencia. Los tres operadores fijan precios sobre exactamente los mismos 377 partidos y los encuentros de una temporada comparten equipos y contexto. Las métricas son, por tanto, medidas relacionadas. Compararlas como si fueran muestras independientes subestimaría la incertidumbre. Además, el análisis considera varios operadores, resultados y niveles de probabilidad, lo que incrementa el riesgo de destacar patrones locales por multiplicidad.

7.2 Sensibilidad al agrupamiento y a la normalización

El ECE depende de los intervalos elegidos. Diez grupos de igual ancho facilitan la interpretación, pero no son la única opción. La verificación con 5 y 20 intervalos apoya la estabilidad general, aunque algunos puntos extremos siguen basándose en pocos partidos. Tampoco se implementó el método de Shin; su incorporación sería una extensión útil para contrastar los tres ajustes ya utilizados.

7.3 Cobertura, validación externa e incertidumbre

El alcance se limita a la Premier League 2021/22 y a tres operadores. No existe una segunda temporada utilizada como validación externa, por lo que no puede asegurarse que los patrones se repitan en el tiempo. La cobertura histórica de operadores cambia, y la advertencia de Pinnacle demuestra que los problemas de calidad de datos pueden modificar una comparación aparente.

Las curvas se interpretaron mediante tamaño de intervalo y análisis de sensibilidad, pero el documento no incorpora intervalos de confianza formales para cada punto. Un trabajo posterior debería utilizar intervalos de Wilson o remuestreo que respete la estructura por partido y equipo.

7.4 Qué no permite concluir el diseño

El diseño no permite afirmar que una desviación de calibración sea explotable, que un operador sea estrictamente mejor que otro, que el patrón por nivel tenga una causa específica o que las probabilidades de gol visitante se mantengan en otras temporadas. Las conclusiones son descriptivas y se refieren al conjunto histórico analizado.

7.5 Número de operadores y extensibilidad del flujo

El análisis se limitó a tres casas de apuestas: Bet365 (B365), Betway/BetAndWin (BW) e Interwetten (IW). Ampliar el estudio a un mayor número de operadores no resulta posible de forma directa con la versión actual del flujo de código: los scripts en R están diseñados específicamente para las columnas de cierre de estos tres operadores, y el diccionario de variables que filtra el archivo E0.csv nombra explícitamente dichas columnas (prefijos B365, BW e IW). Incorporar un cuarto operador requeriría actualizar el diccionario de filtrado, extender las rutinas de cálculo de margen y normalización, y verificar que el nuevo operador tenga cobertura completa en la misma temporada analizada. Esta restricción deriva de decisiones de diseño del repositorio y no de la disponibilidad de datos en la fuente.

8. Uso de Inteligencia Artificial

Durante el desarrollo técnico se utilizó Claude (Anthropic) como apoyo para explorar variables, construir y depurar scripts en R, calcular margen y probabilidades normalizadas, implementar los análisis de calibración, generar el inventario de cobertura y organizar el flujo maestro. En la etapa de consolidación del informe se utilizó ChatGPT (OpenAI) para comparar dos versiones del documento, reorganizar la redacción, ajustar la extensión y conservar los resultados mejor sustentados.

Ningún resultado se aceptó únicamente porque fuera sugerido por una herramienta. Las fórmulas y cifras fueron contrastadas con los archivos del proyecto, las salidas de R y los dos informes de trabajo. También se revisó que el documento final no utilizara probabilidades brutas como evidencia de calibración, que distinguiera magnitud descriptiva de significancia estadística y que no presentara los hallazgos como una recomendación de apuesta.

La bitácora completa se incluye en el Anexo 1. Cada entrada resume el objetivo, la consulta realizada y la forma en que el equipo verificó o corrigió la respuesta de la herramienta.

Anexo 1. Bitácora de uso de Inteligencia Artificial

<https://github.com/agastelbondo/Betting-Sports/commit/bf97787af4dc9bc338860cda32b1b9a406bc533e>

Referencias

- Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1), 1-3.
- Cain, M., Law, D., & Peel, D. (2000). The favourite-longshot bias and market efficiency in UK football betting. *Scottish Journal of Political Economy*, 47(1), 25-36.
- Constantinou, A. C., & Fenton, N. E. (2013). Profiting from arbitrage and odds biases of the European football gambling market. *Journal of Gambling Business and Economics*, 7(2), 41-70.
- DeGroot, M. H., & Fienberg, S. E. (1983). The comparison and evaluation of forecasters. *Journal of the Royal Statistical Society: Series D*, 32(1-2), 12-22.
- Dixon, M. J., & Coles, S. G. (1997). Modelling association football scores and inefficiencies in the football betting market. *Journal of the Royal Statistical Society: Series C*, 46(2), 265-280.
- football-data.co.uk. (2022). Premier League results and betting odds 2021/22 [Conjunto de datos]. <https://www.football-data.co.uk/englandm.php>
- Murphy, A. H. (1973). A new vector partition of the probability score. *Journal of Applied Meteorology*, 12(4), 595-600.
- Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. *Proceedings of the 22nd International Conference on Machine Learning*, 625-632.
- Shin, H. S. (1993). Measuring the incidence of insider trading in a market for state-contingent claims. *The Economic Journal*, 103(420), 1141-1153.
- Štrumbelj, E. (2014). On determining probability forecasts from betting odds. *International Journal of Forecasting*, 30(4), 934-943.
- Woodland, L. M., & Woodland, B. M. (1994). Market efficiency and the favourite-longshot bias: The baseball betting market. *Journal of Finance*, 49(1), 269-279.